

Instituto Tecnológico de Buenos Aires

22.67 SEÑALES ALEATORIAS

Trabajo práctico N°3

Grupo 1:

LAMBERTUCCI, Guido Enrique	58009
LONDERO BONAPARTE, Tomás Guillermo	58150
MUSICH, Francisco	58124

Profesor

HIRCHOREN, Gustavo Abraham

Presentado: 07/02/22

Índice

1. Introducción	2
2. Estimación de la Autocorrelación	2
3. Coeficientes de correlación parcial	2
4. Modelo del proceso	2
5. Matrices de la ecuación Yule-Wlaker	3
6. Filtro de Kalman	4
6.1. Introducción	4
6.2. Modelo en variables de estado	4
6.3. Implementación del filtro recursivo	4
7. Análisis de resultados	5
8. Conclusiones	6
9. Código implementado	6

1. Introducción

Se analiza una secuencia $X(n)$ de 32768 muestras, estimando y calculando parámetros de interés, como lo son la autocorrelación, los coeficientes de correlación parcial, a partir de estos se generará un modelo AR con el propósito de ajustar dicha serie, y con los coeficientes autoregresivos diseñar un modelo en variables de estados del sistema para utilizar un filtro de Kalman.

A la secuencia se le agregará ruido blanco gaussiano aditivo (AWGN) para simular el ruido de medición.

Cabe destacar que en este informe se hará referencia a una variable p , esta tiene un rango entre 1 y 9.

2. Estimación de la Autocorrelación

Se estiman la autocorrelación mediante el uso de los primeros p elementos de la secuencia brindada. Para ello, se vale del no polarizados (R_{np}) de dicho parámetro. Esta función es empleadas para estimar otras funciones mediante información digitalizada.

$$R_{np}(k) = \frac{1}{N-k} \sum_{i=0}^{N-k-1} X(i)X(i+k) \quad (1)$$




Figura 1: Grafica de los coeficientes de autocorrelación total estimados.

3. Coeficientes de correlación parcial

Con los datos ya extraídos y mediante la resolución de la ecuación de Yule-Walker, fue posible obtener los coeficientes deseados. Esto se realizó con los coeficientes totales obtenidos a través de la estimación no polarizada.




Figura 2: Grafica de los coeficientes de autocorrelación parcial obtenidos.

4. Modelo del proceso

El tipo de modelo a utilizar para el proceso será un Auto Regresivo, se utilizará un AR(p).

Para el calculo de los ϕ , son los obtenidos de la matriz de Yule Walker para cada p .

5. Matrices de la ecuación Yule-Wlaker

- Orden 2:

$$\phi = \begin{pmatrix} 0.1473 \\ 0.0481 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 \\ 0.1547 & 1 \end{pmatrix}$$

- Orden 3:

$$\phi = \begin{pmatrix} 0.1454 \\ 0.0423 \\ 0.0396 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 \\ 0.1547 & 1 & 0.1647 \\ 0.0709 & 0.1547 & 1 \end{pmatrix}$$

- Orden 4:

$$\phi = \begin{pmatrix} 0.1441 \\ 0.0410 \\ 0.0351 \\ 0.0312 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 & 0.0564 \\ 0.1547 & 1 & 0.1647 & 0.0709 \\ 0.0709 & 0.1547 & 1 & 0.1547 \\ 0.0564 & 0.0709 & 0.1547 & 1 \end{pmatrix}$$

- Orden 5:

$$\phi = \begin{pmatrix} 0.1432 \\ 0.0399 \\ 0.0338 \\ 0.0268 \\ 0.0304 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 \\ 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 \\ 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 \\ 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 \\ 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 \end{pmatrix}$$

- Orden 6:

$$\phi = \begin{pmatrix} 0.1427 \\ 0.0395 \\ 0.0333 \\ 0.0262 \\ 0.0282 \\ 0.0157 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 \\ 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 \\ 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 \\ 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 \\ 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 \\ 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 \end{pmatrix}$$

- Orden 7:

$$\phi = \begin{pmatrix} 0.1424 \\ 0.0390 \\ 0.0328 \\ 0.0256 \\ 0.0275 \\ 0.0131 \\ 0.0180 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 & 0.0322 \\ 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 \\ 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 \\ 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 \\ 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 \\ 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 \\ 0.0322 & 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 \end{pmatrix}$$

- Orden 8:

$$\phi = \begin{pmatrix} 0.1422 \\ 0.0388 \\ 0.0324 \\ 0.0252 \\ 0.0270 \\ 0.0125 \\ 0.0160 \\ 0.0144 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 & 0.0322 & 0.0314 \\ 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 & 0.0322 \\ 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 \\ 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 \\ 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 \\ 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 \\ 0.0322 & 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 \\ 0.0314 & 0.0322 & 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 \end{pmatrix}$$

- Orden 9:

$$\phi = \begin{pmatrix} 0.1420 \\ 0.0386 \\ 0.0323 \\ 0.0250 \\ 0.0268 \\ 0.0122 \\ 0.0156 \\ 0.0132 \\ 0.0090 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 & 0.0322 & 0.0314 & 0.0277 \\ 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 & 0.0322 & 0.0314 \\ 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 & 0.0322 \\ 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 & 0.0461 \\ 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 & 0.0477 \\ 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 & 0.0564 \\ 0.0322 & 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 & 0.0709 \\ 0.0314 & 0.0322 & 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 & 0.1547 \\ 0.0277 & 0.0314 & 0.0322 & 0.0461 & 0.0477 & 0.0564 & 0.0709 & 0.1547 & 1 \end{pmatrix}$$

6. Filtro de Kalman

6.1. Introducción

En el campo de la estadística y teoría de control, los filtros de Kalman, también conocidos como estimación cuadrática media (LQE), es un algoritmo que utiliza una serie de mediciones realizadas por un observador a través del tiempo, el cual contiene ruido estadístico y otras incertezas, y produce estimaciones de variables, que tienden a ser mucho más acertadas que otras basadas en una única medición, al estimar la distribución de probabilidad conjunta sobre las variables por cada tiempo t_k . El filtro es llamado así por su desarrollador, Rudolf E. Kálmán. En filtro de Kalman puede ser escrito en una sola ecuación, sin embargo a menudo se conceptualiza como dos fases distintas.

La fase de predicción y la de actualización. La fase de predicción usa la predicción del estado $k - 1$ para producir un estimado del estado actual. Esta predicción del estado también es conocida como la estimación a-priori y no cuenta con información de la observación actual. En la fase de actualización la diferencia entre la predicción a-priori y la observación actual, son multiplicadas por la ganancia de Kalman, y combinada con la última estimación, para mejorarla, esto es conocido como el estimador a-posteriori.

Estas dos etapas se van turnando usualmente.

6.2. Modelo en variables de estado

Para el modelo en variables de estado, se tuvieron en cuenta las siguientes matrices:

- La matriz Φ también conocida como la matriz de transición de estados está construida de la siguiente manera: la primera fila son los coeficientes del modelo autoregresivo, mientras que para el resto es la identidad.
- La matriz H también conocida como el modelo de observación es una matriz nula excepto en la posición (0,0) donde vale 1.
- Q es la matriz de covarianza de ruido del proceso: Es una matriz cuadrada de $p \times p$ donde el término $[0,0]$ es el ruido del proceso.
- R es la matriz de covarianza de ruido de observación: es una matriz cuadrada de $p \times p$ diagonal con valor σ_v^2

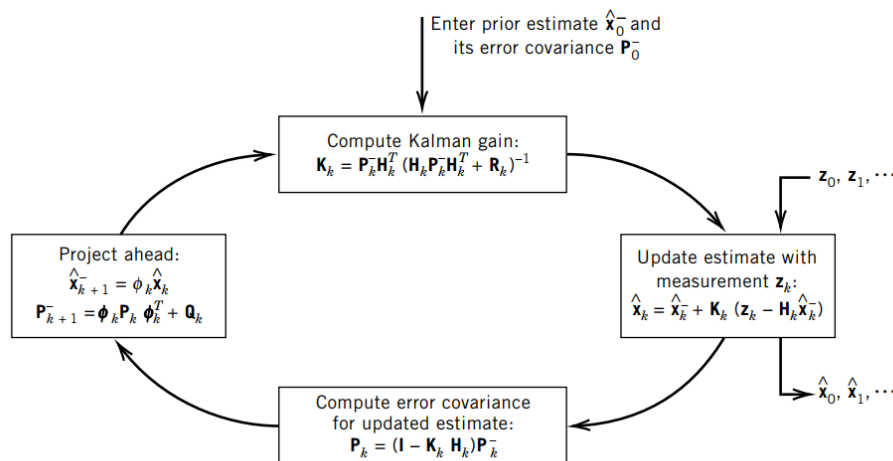


Figura 3: Ciclo del filtro de Kalman.

6.3. Implementación del filtro recursivo

En la implementación del filtro se utilizó las variables de estado detalladas en la anterior sección.

En el caso del trabajo práctico se generó una secuencia v_k de ruido blanco y gaussiano con varianza $R=\sigma_v^2$ y se sumó a la secuencia x_k . Y a esto se le aplicó el filtro de Kalman, finalmente se hizo lo mismo pero variado el valor de σ_v^2 .

7. Análisis de resultados

A continuación se observan la señal de entrada, la señal medida y la de salida del filtro..

Aquí se observa como es la relación señal a ruido sin la utilización del filtro de Kalman, y por otro lado su mejora al utilizarlo.




Figura 4: Comparación de entrada, medición y predicción del sistema.

Además se varió el valor del σ_v^2 entre $0.01 \sim 100$ y se observó la gran mejora porcentual del MSE en función del sigma, viendo que cuanto mayor es la varianza mayor es la mejora porcentual

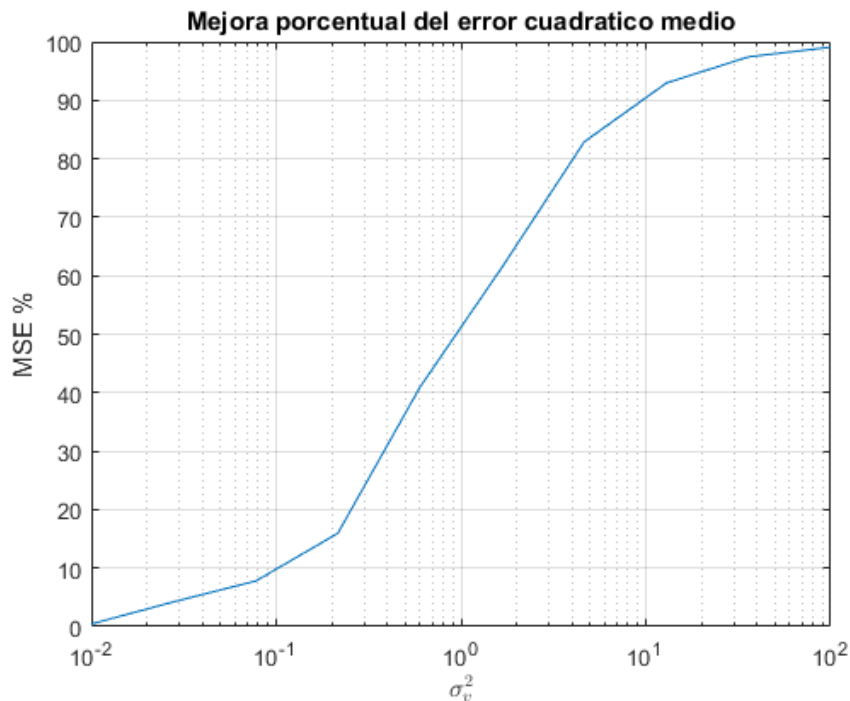


Figura 5: Variación del error porcentual en función de la varianza.

8. Conclusiones

Se observó como la utilización de un filtro de Kalman reduce significativamente el MSE en un entorno ruidoso. Una herramienta sumamente útil múltiples campos. Definitivamente en entornos donde se trata con mediciones del mundo físico el cual está sumido en ruidos. Al ser un filtro recursivo permite una mayor velocidad de cómputo que algunos que no lo son debido a que no debe tener una memoria tan grande.

9. Código implementado

A continuación se muestra todo el código utilizado en el proyecto.

■ Main.m:

```

1  clc
2  clear
3  close all
4  fprintf('Welcome to GTI matlab script for Kalman filtering\r\n');
5
6  %Constants usefull to alter the behaviour of the script
7  kmax=9;%Value of P
8  SAMPLES=100;
9  LOGSPACELEN = 10;
10
11 %Buffers for variables.
12 R_vars_buffer=logspace(-2,2,LOGSPACELEN);%different values for the variance of
    the measurment
13 error_improvement = zeros(1,LOGSPACELEN);
14 mse_measure_b=zeros(1,kmax);
15 mse_filter_b=zeros(1,kmax);
16
17 %%actual script
18 x=load('h06g1.dat');%loads the sample vector
19
20 xs=x(1:SAMPLES);%gets a subarray to make it faster to process, if desired SAMPLES
    can be changed to a a value between 1 and size(x)
21
22 for j = 1:LOGSPACELEN%For each Variance
23
24     for i = 1:kmax%For every p
25
26         Rxxnp = Rnp(x,i+1);%Estimate the Autocorrelation function using a non
            polarized estimator
27         rxxnp = Rxxnp./Rxxnp(1); %Normalize it
28
29         if (j==1 && i==kmax)
30             [phiknp, phiv, phiVarn] = cpar(rxxnp, i+1,1);%Obtain the partial
                correlation coeffients by solving the Yule Walker equation.
31         else
32             [phiknp, phiv, phiVarn] = cpar(rxxnp, i+1,0);%Obtain the partial
                correlation coeffients by solving the Yule Walker equation.
33         end
34
35         % Kalman matrices.
36         PHI = [phiv'; eye(i-1) zeros(i-1,1)];%Phi matrix for the Kalman filter,
            also known as the State transition model
37         %%The first row is the AR coefficients, the other is the Identity
38         %%matrix
39         H = zeros(i,i);% Observation model
40         H(1,1)=1;
41

```

```

42     varX=var(x);
43     varNoise= var(x)*(1-dot(phiVarn(i,1:i),rxxnp(2:i+1)));
44     Q=zeros(i);
45     Q(1,1)=varNoise;%Create the Covariance of process noise
46
47     R=eye(i)*R_vars_buffer(j); %R Covariance of observation noise
48
49     z = xs + sqrt(R(1,1)) * randn(size(xs)); %Measurement of the signal
50     z=make_extended(z,i);%Extends the measurment vector to make it fit for
        the AR model.
51
52     xhat = kalman(z, PHI, H, R, Q);%With the Matrices defined, apply the
        Kalman filter to the sequence
53
54     Yhat= (H*xhat);%Apply the observation matrix to obtain the i
55     Yhat=Yhat(1,:);
56     zinput=z(1,:);
57
58     measurement_error = (xs-zinput).^2;
59     filter_error = (xs-Yhat).^2;
60     mse_measure_b(i) = mean(measurement_error);
61     mse_filter_b(i) = mean(filter_error);
62
63     if (i == kmax)
64         error_improvement(j) = mean((mse_measure_b - mse_filter_b)*100/
            mse_measure_b);
65     end
66
67     if (i==kmax && j==LOGSPACELEN-4)
68         hold on
69         plot(zinput, 'g')
70         plot(xs, 'k')
71         plot(Yhat, 'r')
72
73         legend({'Measurement','Input', 'Estimated'})
74         xlabel('Samples [n]');
75         ylabel('Amplitude ');
76         title(sprintf(' \sigma_v^2 = %.4f ~ p = %i ~ MSE-{Input-
            Measure} = %.4f ~ MSE-{Input-Filter} = %.4f', R_vars_buffer(j),
            i, mse_measure_b(i), mse_filter_b(i)), 'interpreter', 'latex');
77         suptitle('Kalman Filtering Stages');
78         grid on;
79         hold off
80         if(j ~= LOGSPACELEN)
81             figure();
82         end
83
84     end
85 end
86 end
87
88 semilogx(R_vars_buffer, error_improvement);
89 grid on;
90 title('Mejora porcentual del error cuadratico medio');
91 xlabel(sprintf(' \sigma_v^2 '), 'interpreter', 'latex');
92 ylabel('MSE %');
93
94 function xtended = make_extended(x,k)
95     size_ = size(x);

```



```

96     size_=size_(2);
97     xtended=zeros(k, size_);
98     for i = 1:k
99         xtended(i,:) = [zeros(1,i-1) x(1:size_-(i-1))];
100         %El extendido con I maneje todo
101     end
102 end

```

■ Cpar.m:

```

1  function [phikk, phi, phis_triang] = cpar(rxx, kmax, flag_print)
2
3      phikk = rxx(2);
4      phis_triang=zeros(kmax-1);
5      phi = rxx(2);
6      phis_triang(1,1)=rxx(2);
7      for i = 2:kmax-1
8
9          R = toeplitz([rxx(1:i)]);
10         phi = linsolve(R, rxx(2:i+1).'); %%Resuelvo el sistema de ecuaciones para
            obtener los phikk
11         phikk = [phikk, phi(end)];
12         phis_triang(i,:) = [phi' zeros(1, kmax-1-i)];
13         if(flag_print)
14             fprintf('Yule walker matrices %i\r\n', i)
15             phi
16             R
17         end
18     end
19 end

```

■ Rnp.m:

```

1  function [Rxx] = Rnp(x, kmax)
2      N=max(size(x));
3      Rxx=0;
4      for i = 0:kmax-1
5          Rxx=[Rxx, (sum(x(1:N-i) .* x(i+1:N)) * (1/(N-i)))]; %%aplico el algoritmo
6      end
7      Rxx=Rxx(2:end);
8  end

```

■ kalman.m:

```

1  function xhat = kalman(z, Phi, H, R, Q)
2
3      % z Measurement signal          m observations X # of observations
4      % Phi State transition model     n X n, n = # of state values
5      % H Observation model            m X n
6      % R Covariance of observation noise m X m
7      % Q Covariance of process noise  n X n
8
9      m = size(H, 1); %Number of sensors
10     n = size(H, 2); %Number of state values
11     numobs = size(z, 2); %Number of observations
12     xhat = zeros(n, numobs); %Observation
13
14
15     %Initialize P, I
16     P = ones(size(Phi));

```

```
17 I = eye(size(Phi));
18
19 %Kalman Filter
20 for k = 2:numobs
21     %Predict
22     xhat_acotado=xhat(:,k-1);
23
24     xhat(:,k) = Phi*xhat_acotado; %Shamugan 7.133 pag 433
25     P = Phi*P*Phi' + Q; %Borwn picture 4.1 pag 147
26
27     %Update
28     num = P*H';
29     den = (H*P*H' + R);
30     K = num/den;
31     P = (I - K*H)*P;
32     xhat(:,k) = xhat(:,k) + K*(z(:,k) - H*xhat(:,k));
33 end
```